Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

Spracovanie prirodzeného jazyka

SemEval 2025 Task 9: The Food Hazard Detection Challenge

Etapa I.

Spracovali:
Ján Schmiedbauer
Patrik Sedlák
Anastasiia Kolisnyk

Akad. rok: 2026/2027

Obsah

1 Formulácia problému, ciele a motivácia projektu **2**

2 Dataset, relevantná literatúra, prehľad existujúcich riešení **2**

2.1 Prehľad riešení dosahujúcich najlepšie výsledky 3

2.1.1 SRCB (Ricoh Software Research Center (Beijing)) [1] 3

2.1.2 Anastasia [2] 4

2.1.3 MyMy [3] 5

2.1.4 PATeam [4] 6

3 Vyhodnocovacie metriky a metodológia **7**

3.1 Metodológia 7

4 Návrh a implementácia baseline riešenia **8**

4.1 Návrh baseline riešenia 8

4.2 Implementácia baseline riešenia 9

4.2.1 Príprava dát 9

4.2.2 Augmentácia dát 9

4.2.3 Modul výberu kandidátov 9

4.2.4 Predikcia pomocou LLM 9

5 Výsledky baseline riešenia **10**

6 Použitie agentov a LLM mimo riešenia **10**

1 Formulácia problému, ciele a motivácia projektu

Presné a včasné informácie o nebezpečných látkach v potravinách sú dôležitou témou, pretože môžu priamo ovplyvniť verejné zdravie. Zároveň sú tieto informácie veľmi dôležité aj pre výrobcov potravín, keďže sťahovanie potravín z trhu môže spôsobiť značné finančné škody. Automatizované systémy, ktoré prehľadávajú relevantné správy o potravinových incidentoch a extrahujú z nich nebezpečnú látku a dotknutý produkt, by mohli pomôcť expertom a potravinovým úradom široko monitorovať výskyt nebezpečných látok v produktoch. Súťaž SemEval-2025 Task 9 [5] sa priamo zameriava na túto tému. Jej cieľom je posúdiť, ako dobre dokážu modely strojového učenia extrahovať údaje o nebezpečných látkach v potravinách zo zašumených reálnych oznámení o sťahovaní produktov z trhu, ktoré zverejňujú oficiálne potravinové úrady, najmä v Spojených štátoch, Spojenom kráľovstve, Kanade a Austrálii.

Súťaž je rozdelená na dve podúlohy. V prvej podúlohe (ST1) je cieľom správne určiť širšiu kategóriu nebezpečnej látky (hazardu) aj príslušného produktu, pričom existuje 10 kategórií hazardov a 22 kategórií produktov [4]. V druhej, náročnejšej podúlohe (ST2) je cieľom správne určiť presný hazard a dotknutý produkt, pričom je k dispozícii 128 označení (labelov) pre hazardy a 1 142 pre produkty [4]. Druhá podúloha bola zavedená ako spôsob, ako v širšom zmysle zdôvodniť, prečo bola správa zaradená do určitej kategórie, napr. „Táto správa sa týka allergens (kategória hazardu), pretože spomína pecan nut (hazard).“ Napriek tomu 21 z 27 odovzdaných riešení uprednostnilo samostatné pipeline pre každú z podúloh a iba 5 riešení sa rozhodlo využiť koreláciu medzi nimi [5].

Cieľom tejto etapy projektu je vytvoriť vhodné baseline riešenie, ktoré bude zohľadňovať trendy nájdené v ostatných riešeniach odovzdaných do tejto súťaže. V rámci súťaže boli poskytnuté tri referenčné riešenia: riešenie založené na TF-IDF, riešenie založené na modeli BERT a riešenie založené na metóde CICLe [5, 6]. Naše baseline riešenie bude následne porovnané s týmito tromi referenčnými riešeniami na základe oficiálnej metriky a zároveň bude ukázané, kde by sa umiestnilo v oficiálnom rebríčku.

2 Dataset, relevantná literatúra, prehľad existujúcich riešení

Dataset poskytnutý pre túto súťaž obsahuje 7 546 oznámení o sťahovaní potravín z trhu. Riešenia v súťaži však boli hodnotené iba na správach v anglickom jazyku, ktorých je 6 644 [5, 7]. Zvyšných 902 správ v iných jazykoch bolo do datasetu pridaných iba ako doplnkové trénovacie dáta. Finálna verzia datasetu použitá v súťaži je verejne dostupná na platforme Zenodo [7].

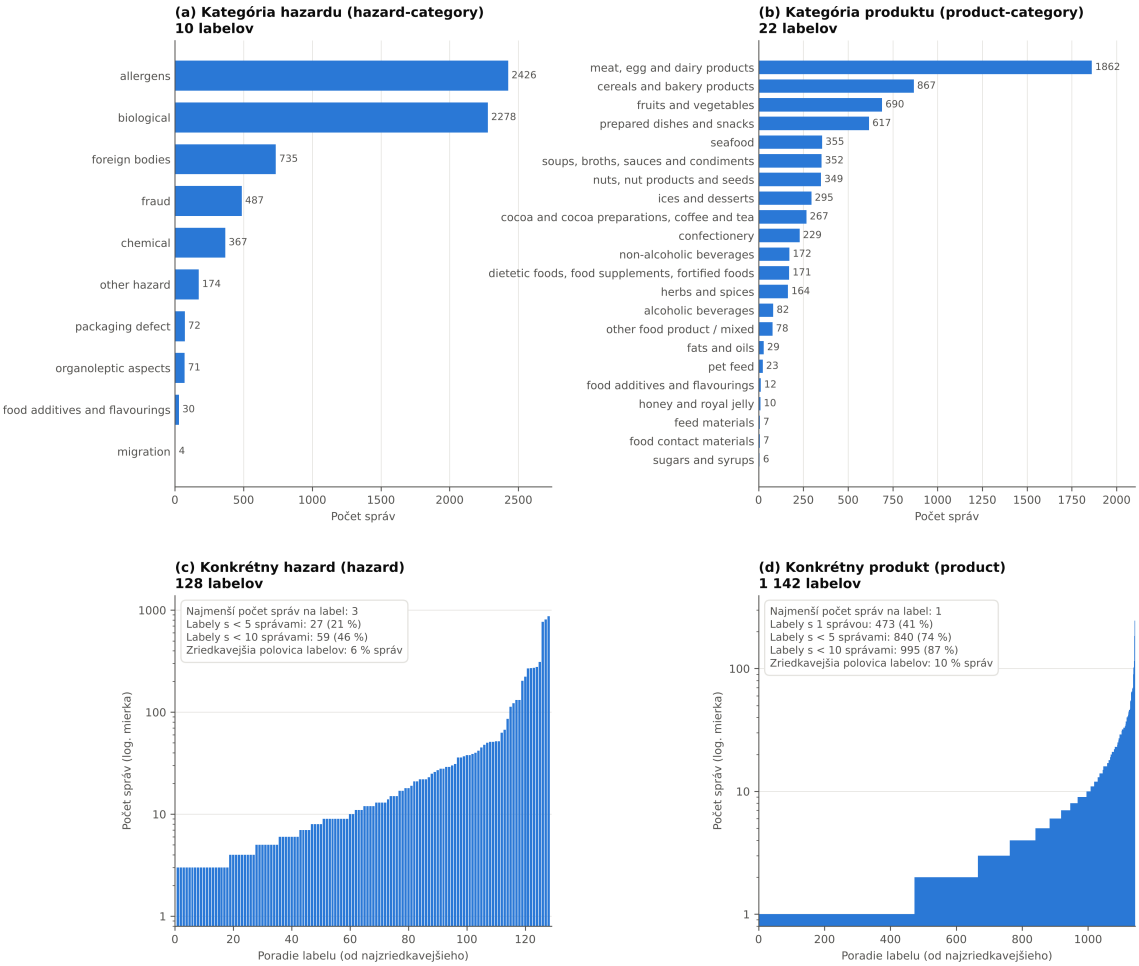
Správy boli získané z webových stránok 24 oficiálnych vládnych potravinových úradov (najmä v USA, Spojenom kráľovstve, Kanade a Austrálii) a anotované expertmi v spolupráci so spoločnosťou Agroknow [7]. Dataset poskytuje 6 vstupných atribútov:

- *title* – názov oznámenia,
- *text* – neupravený text oznámenia,
- *country* – krajina vydania,
- *year* – rok zverejnenia správy,
- *month* – mesiac zverejnenia správy,
- *day* – deň zverejnenia správy.

Ako uvádza oficiálny článok, väčšina riešení využívala iba atribúty *title* a *text* (prípadne iba jeden z nich) a len 3 z 27 tímov sa rozhodli použiť všetky dostupné atribúty [5].

Cieľovými atribútmi sú vyššie spomínané kategórie a konkrétne označenia:

- *product-category* – kategória produktu, 22 labelov, použitá v podúlohe 1,
- *hazard-category* – kategória hazardu, 10 labelov, použitá v podúlohe 1,
- *product* – konkrétny produkt, 1 142 labelov, použitý v podúlohe 2,
- *hazard* – konkrétny hazard, 128 labelov, použité v podúlohe 2.



Obr. 1: Distribúcie cieľových atribút v poskytnutom datasete.

Výraznou vlastnosťou, ktorá túto súťaž sťažuje, je silná nevyváženosť tried v datasete. Každý cieľový atribút má rozdelenie labelov s dlhým chvostom (long-tailed distribution), teda s množstvom zriedkavých tried (viď obrázok 1) [5]. Všetky 4 najlepšie riešenia opísané v oficiálnom článku sa tento problém rozhodli riešiť priamo, pomocou augmentácie dát [1–4].

2.1 Prehľad riešení dosahujúcich najlepšie výsledky

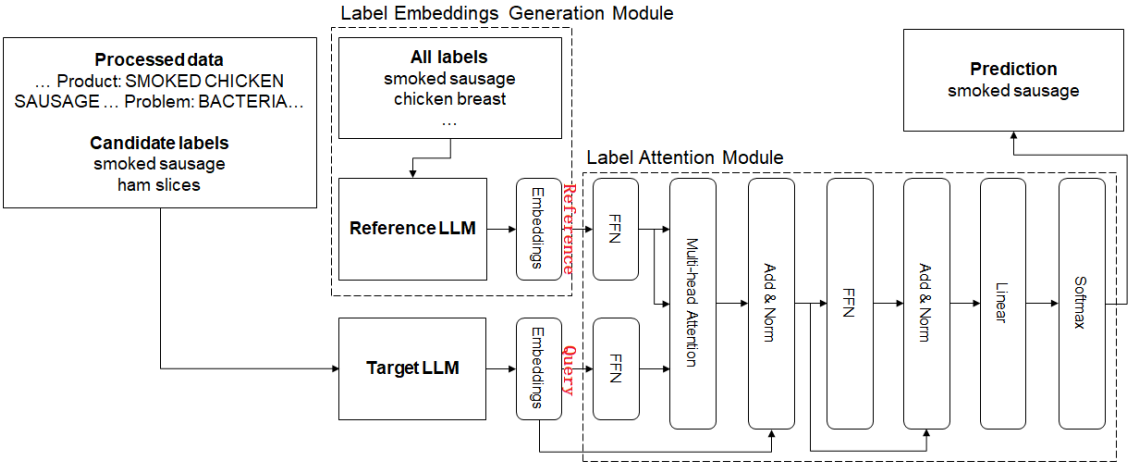
Najdôležitejším literárnym zdrojom pre tento projekt je oficiálna správa k SemEval-2025 Task 9 [5]. Táto správa obsahuje sekciu, v ktorej sú vyzdvihnuté 4 najlepšie odovzdané riešenia spolu s odkazmi na ich jednotlivé články. V nasledujúcich podkapitolách budú stručne opísané metódy použité v týchto riešeniach. Tieto informácie budú následne použité na sformulovanie vhodného baseline riešenia pre tento projekt.

2.1.1 SRCB (Ricoh Software Research Center (Beijing)) [1]

V rámci predspracovania dát systém najprv spojí atribúty *title* a *text* (ktoré boli jedinými použitými vstupnými atribútmi) do jedného textu, ktorý je následne vyčistený od rôznych textových artefaktov, ako sú zalomenia riadkov, nadbytočné medzery, duplicitné riadky a pod. Výsledné texty sú následne skrátené na maximálnu dĺžku v tokenoch, aby mohli byť použité ako vstupy pre dva moduly, ktoré systém využíva (512, resp. 1024 tokenov).

Na augmentáciu dát bola použitá metóda využívajúca LLM (konkrétne model Qwen2.5-72B-Instruct), pričom LLM bol inštruovaný vytvoriť novú vzorku, ktorá preberá význam a označenie cieľovej vzorky zo zriedkavej triedy (menej ako 50 výskytov v trénovacích dátach) a štýl písania a formát náhodne vybranej vzorky.

Samotný systém využíval dva hlavné moduly: modul na výber kandidátov (candidate recall module) a modul



Obr. 2: Architektúra modulu predikcie pomocou LLM (prevzaté priamo z [1]).

predikcie pomocou LLM (LLM prediction module). Úlohou modulu na výber kandidátov je zúžiť množinu možných výstupných označení pred výpočtovo náročnejšou predikciou pomocou LLM. Tento modul využíva prístup one-vs-all, pričom pre každé označenie je zostrojený binárny klasifikátor nad architektúrou BERT. Tento prístup bol zvolený, pretože autori experimentovali s modelom RoBERTa-base a zistili, že hoci skóre klasifikácie bolo pomerne slabé, hodnota recall presahovala 95 %, čo naznačuje, že správne označenie sa takmer vždy nachádza medzi kandidátskymi označeniami na výstupe modelu BERT. Vo finálnom odovzdanom riešení bol tento modul zostavený s použitím modelov RoBERTa-base a DeBERTaV3-base.

Modul predikcie pomocou LLM je zložitejší a zahŕňa dva LLM: doladený (fine-tuned) cieľový LLM a zmrazený referenčný LLM, ktorý je použitý na predvýpočet embeddingov všetkých označení ešte pred trénovaním. Tieto embeddingy sú následne použité ako externé doplnkové znalosti spolu s výstupom cieľového LLM (ktorý na vstupe dostáva naformátovaný text a zúženú množinu označení z predchádzajúceho modulu) v module multi-head attention, ktorého výstupy sú následne použité na vygenerovanie výsledného označenia vo forme textu. Pre obe roly autori použili model Qwen2.5-14B-Base. Finálne odovzdané riešenie tohto tímu kombinovalo niekoľko variantov tejto pipeline pomocou väčšinového hlasovania, avšak presné detaily použitých variantov nie sú v správe opísané.

Toto riešenie sa umiestnilo na treťom mieste v ST1 a na prvom(!) mieste v ST2, pričom pre každú podúlohu bola použitá samostatná, no architektonicky rovnaká pipeline.

2.1.2 Anastasia [2]

Tento systém využíva ensemble prístup a zameriava sa výlučne na ST1. V rámci predspracovania dát systém najprv (zrejme) spojí všetky poskytnuté vstupné atribúty. Následne sú aplikované štandardné techniky čistenia textu na odstránenie artefaktov, podobne ako v riešení SRCB. Potom je použitá augmentácia dát v rôznej miere (vrátane žiadnej) na vytvorenie troch samostatných datasetov, ktoré sú využívané modulmi systému. Záznamy výsledných datasetov sú následne rozdelené na úseky (chunky) založené na vetách s rôznou veľkosťou, aby mohli byť použité ako vstupy pre jednotlivé modely v moduloch, konkrétne s veľkosťou 512, 768, 1024 a 1280 tokenov.

Použité boli tieto tri datasety:

1. *Original* – neobsahuje syntetické vzorky, iba techniky oversamplingu a undersamplingu, ktoré boli použité na vyváženie datasetu
2. *Light Augmentation* – obsahuje augmentované dáta, konkrétne syntetické vzorky málo zastúpených tried (presná metóda vytvorenia týchto vzoriek nie je v článku opísaná)
3. *Heavy Augmentation* – rovnaký ako Light Augmentation, avšak s väčším množstvom syntetických vzoriek a dodatočnými krokmi spracovania

Pri datasete *Heavy Augmentation* boli použité dodatočné techniky spracovania, ako napríklad odstránenie HTML tagov pomocou knižnice BeautifulSoup [8] a preklad neanglických záznamov obsiahnutých v pôvodných dátach, čo pomohlo ďalej zvýšiť konzistenciu a veľkosť tejto verzie datasetu.

METHOD	DATA	MODEL NAME	TOKEN CHUNK	HAZARD SCORE	PRODUCT SCORE	SCORE	WEIGHT HAZARD	WEIGHT PRODUCT
Single-Task	Light	DeBERTa-v3-large	512	0.7861	0.7486	0.7673	0.3500	0.1842
			768	0.7990	0.7640	0.7815	0.3500	0.2632
			1024	0.7789	0.7960	0.7874	0.0000	0.0000
			1280	0.7819	0.7875	0.7847	0.2000	0.0000
		RoBERTa-large	512	0.7680	0.7515	0.7598	0.0500	0.1842
			768	0.7691	0.8292	0.7991	0.0000	0.0000
			1024	0.7719	0.7522	0.7621	0.0000	0.0000
			1280	0.7839	0.7869	0.7854	0.0000	0.0000
	Heavy	DeBERTa-v3-large	512	0.7613	0.7945	0.7779	0.0500	0.2632
			768	0.7712	0.7984	0.7848	0.0000	0.0000
			1024	0.7599	0.7490	0.7544	0.0000	0.0000
		RoBERTa-large	512	0.7775	0.7837	0.7806	0.0000	0.0000
MultiTask	Original	DeBERTa-v3-large	512	0.7291	0.7963	0.7627	0.0000	0.1053

Obr. 3: Presné kombinácie modelov použitých v riešení. Každý single-task riadok predstavuje dva modely (jeden pre kategóriu hazardu a jeden pre kategóriu produktu) a obsahuje aj výsledné váhy použité pri mäkkom hlasovaní (prevzaté priamo z [2]).

Ako už bolo spomenuté, toto riešenie využíva tri moduly, pričom dva z nich sa zameriavajú na predikciu jedného cieľového atribútu (single-task), konkrétne kategórie produktu, resp. kategórie hazardu, a tretí na súčasnú predikciu oboch cieľových atribútov (multi-task). Single-task moduly spolu obsahujú 24 modelov (12 konfigurácií pre kategóriu hazardu a 12 pre kategóriu produktu), ktoré vychádzajú z kombinácie datasetu light/heavy, modelu DeBERTa-v3-large/RoBERTa-large a veľkosti chunku 512/768/1024/1280 tokenov. Pre multi-task modul bol použitý iba model DeBERTa-v3-large s veľkosťou chunku 512 tokenov a datasetom *Original*. Pre použité kombinácie viď obrázok 3.

Na získanie finálnej predikcie je samostatne pre kategóriu hazardu a kategóriu produktu použité vážené mäkké hlasovanie (weighted soft voting), pričom presné váhy boli získané pomocou techniky grid search. Ďalším dôležitým aspektom, ktorý je potrebné zdôrazniť, je použitie loss funkcie Focal loss [9]. Táto loss funkcia (viď rovnicu (1)) je navrhnutá tak, aby znižovala vplyv ľahko klasifikovateľných vzoriek a uprednostňovala tie ťažšie, čo ďalej pomáha zmierniť vplyv nevyváženosti datasetu. Táto funkcia bola použitá pri doladení (fine-tuning) všetkých modelov.

$$\mathscr{L}_{FL}(p_t) = -\alpha_t(1-p_t)^{\gamma}\log(p_t) \tag{1}$$

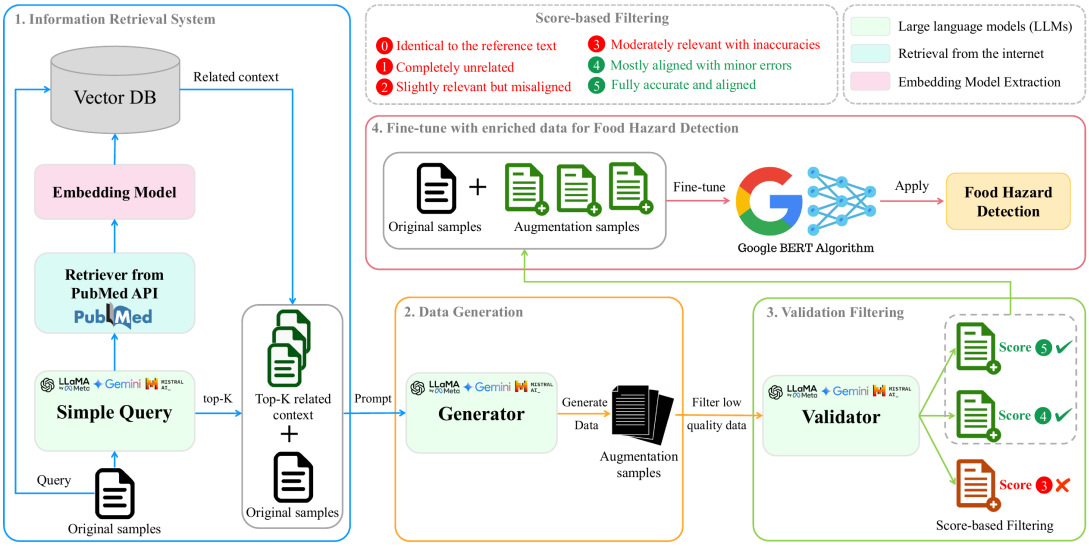
Toto riešenie sa umiestnilo na prvom(!) mieste v ST1. Autori však uvádzajú, že odovzdali viacero testovacích behov, čím porušili pravidlo SemEval o jedinom odovzdaní, čo im mohlo poskytnúť výhodu.

2.1.3 MyMy [3]

Tento systém je pozoruhodný vďaka zameraniu na tvorbu robustných syntetických vzoriek v rámci augmentácie dát. V rámci predspracovania systém zrejme nevyužíva žiadny štandardný postup čistenia textu, pričom autori uvádzajú iba to, že riešenie využíva všetky poskytnuté vstupné atribúty.

Najdôležitejšou súčasťou tohto systému je robustná pipeline na augmentáciu dát, ktorá využíva techniku RAG na tvorbu obsahovo bohatých syntetických vzoriek pridávaných do datasetu na základe kontextových dokumentov získaných z PubMed, verejne dostupnej databázy biomedicínskej literatúry. Najprv sú pôvodné vzorky predané LLM, ktoré sú inštruované vytvoriť pre každú vzorku krátky vyhľadávací dopyt. Účelom tohto kroku je zvýšiť efektivitu získavania dokumentov z PubMed API, ktoré je inak pri zložitých dopytoch náchylné na zlyhanie. Na základe dopytu sú následne z PubMed API získané relevantné dokumenty, ktoré sú potom prevedené na dense vektory a uložené vo vektorovej databáze Chroma na efektívne vyhľadávanie pomocou kosínusovej podobnosti. Ďalej je top-K dokumentov najpodobnejších pôvodnému textu (hodnota tohto parametra nie je v správe uvedená) vložených (spolu so samotným pôvodným textom) do promptu nasledujúceho kroku.

Výsledné prompty sú následne predané LLM, ktoré sú (v rámci promptu) inštruované vytvoriť syntetickú vzorku parafrázovaním pôvodného textu s využitím poskytnutého kontextu. V poslednom kroku augmentácie dát sú výsledné texty predané LLM, ktoré sú inštruované ohodnotiť kvalitu vytvorenej vzorky od 0 do 5 na základe rele-



Obr. 4: Pipeline na augmentáciu dát a architektúra systému použité v riešení MyMy. Google BERT slúži iba na ilustráciu, modely doladené v rámci riešenia boli Gemini Flash 2.0, PubMedBERT a ModernBERT (prevzaté priamo z [3]).

vantnosti a presnosti vzhľadom na priložený kontext. Do výsledného datasetu sú pridané iba vzorky, ktoré získali skóre 4 alebo 5. Týmto filtrovaním úspešne prešlo približne 60 000 augmentovaných vzoriek, ktoré boli pridané do datasetu oproti 5 082 pôvodným vzorkám, čo výrazne pomohlo zväčšiť veľkosť datasetu. V tejto augmentačnej pipeline boli použité modely GPT-3.5 Turbo, Gemini Flash 2.0, Llama 3.1 8B a Mixtral 8x7B.

V porovnaní s pipeline na augmentáciu dát je predikčná pipeline pomerne jednoduchá a využíva modely Gemini Flash 2.0, PubMedBERT a ModernBERT doladené na obohatenom datasete. Predikované označenia sú následne vypočítané pomocou ensemble stratégie, konkrétne spriemerovaním pravdepodobností tried jednotlivých modelov pre každú podúlohu.

Toto riešenie sa umiestnilo na druhom mieste v ST1 aj ST2, čím sa ukázalo ako najvyváženejšie zo spomenutých riešení.

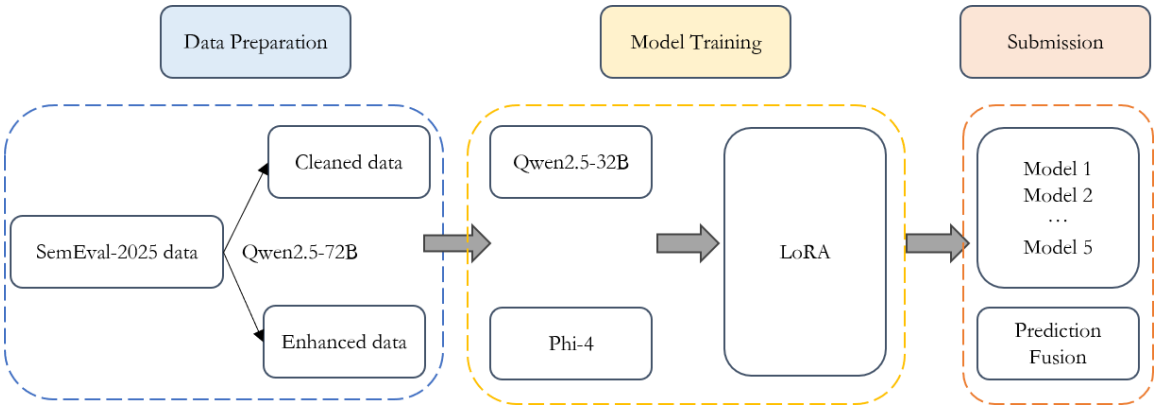
2.1.4 PATeam [4]

Tento systém je pozoruhodný využitím jediného generatívneho LLM, ktorý rieši obe podúlohy spoločne vo forme viackolového dialógu, v kombinácii s bagging ensemble prístupom. V rámci predspracovania autori používajú regulárne výrazy na odstránenie nežiaducich webových artefaktov, ako sú hypertextové odkazy, HTML formátovanie a e-mailové adresy. Použité sú iba vstupné atribúty *title* a *text*.

V rámci augmentácie dát je LLM inštruovaný vygenerovať stručné zhrnutie každého vyčisteného textu, ktoré je následne spojené s pôvodným textom. Na rozdiel od ostatných spomenutých riešení tento prístup nevytvára nové vzorky, ale obohacuje existujúce. Podľa autorov zhrnutia pomáhajú štandardizovať zašumené texty a zvýrazniť informácie relevantné pre označenia produktu a hazardu. LLM použitý na tvorbu zhrnutí nie je v texte článku pomenovaný, avšak prehľad systému (obrázok 5) naznačuje model Qwen2.5-72B. Na riešenie nevyváženosti tried je obohatený dataset následne oversamplovaný tak, aby každá trieda obsahovala aspoň päť vzoriek, pričom autori zistili, že táto hranica dosahuje na validačnej množine najlepšie výsledky.

Samotná predikcia je vykonávaná modelom Phi-4 doladeným pomocou LoRA [10], ktorý formuluje obe podúlohy ako dialóg o dvoch kolách. V prvom kole model dostane nadpis, vyčistený text a vygenerované zhrnutie a predikuje kategóriu hazardu a kategóriu produktu (ST1). V druhom kole sú tieto predikcie pridané do promptu a model je požiadaný, aby určil konkrétnejší hazard a produkt (ST2). Týmto spôsobom všeobecnejšia predikcia usmerňuje tú detailnejšiu. Pre ensemble je použitý prístup bagging [11]: z trénovacích dát je vzorkovaním s opakovaním vytvorených päť podmnožín, na každej z nich je doladený samostatný model Phi-4 a finálna predikcia je získaná hlasovaním týchto piatich modelov (presná schéma hlasovania nie je uvedená).

Toto riešenie sa umiestnilo na štvrtom mieste v ST1 a na treťom mieste v ST2.



Obr. 5: Prehľad systému riešenia PATeam. Hoci je v štádiu trénovania modelu zobrazený model Qwen2.5-32B, všetky uvádzané výsledky boli získané s modelom Phi-4 (prevzaté priamo z [4]).

3 Vyhodnocovacie metriky a metodológia

Na vyhodnotenie nášho baseline riešenia bude použitý rovnaký proces hodnotenia, aký bol v súťaži použitý na vyhodnotenie riešení odovzdaných účastníkmi, a to pre ST1 aj ST2 [5]. Skóre je založené predovšetkým na metrike macro F1, ktorá bola zvolená z dôvodu už spomenutej nevyváženosti tried v datasete, čím je zabezpečené, že skóre nie je ovplyvňované najmä najfrekventovanejšími označeniami (labels). Nasledujúce rovnice opisujú, ako je vypočítané skóre pre každú z podúloh.

Najprv je pomocou rovnice 2 vypočítané skóre macro F1 pre hazard. Tu RCL_i a PRC_i predstavujú recall a precision triedy i a n je celkový počet tried.

$$F_1(y,\hat{y}) = \frac{2}{n}\sum_{i=1}^{n}\frac{\mathrm{RCL}_i(y,\hat{y})\cdot\mathrm{PRC}_i(y,\hat{y})}{\mathrm{RCL}_i(y,\hat{y})+\mathrm{PRC}_i(y,\hat{y})} \tag{2}$$

Následne je dataset prefiltrovaný, pričom sú ponechané iba vzorky, pri ktorých bol hazard predikovaný správne. Táto operácia je matematicky opísaná rovnicou 3. Tu y^h a y^p predstavujú skutočné označenia hazardu a produktu, $\hat{y}^h$ a $\hat{y}^p$ predikované označenia a m je počet vzoriek. $\hat{y}^{p|h}$ je definované analogicky.

$$y^{p|h} = \left\{ y_j^p \;\middle|\; \hat{y}_j^h = y_j^h \right\}, \quad j \in \{1,2,\ldots,m\} \tag{3}$$

Na prefiltrovaný dataset je následne aplikovaná rovnica 2, čím je získané skóre macro F1 pre produkt. Výsledné skóre úlohy je potom vypočítané ako priemer skóre macro F1 pre hazard a produkt (rovnica 4).

$$S(Y,\hat{Y}) = \frac{F_1(y^h,\hat{y}^h) + F_1(y^{p|h},\hat{y}^{p|h})}{2} \tag{4}$$

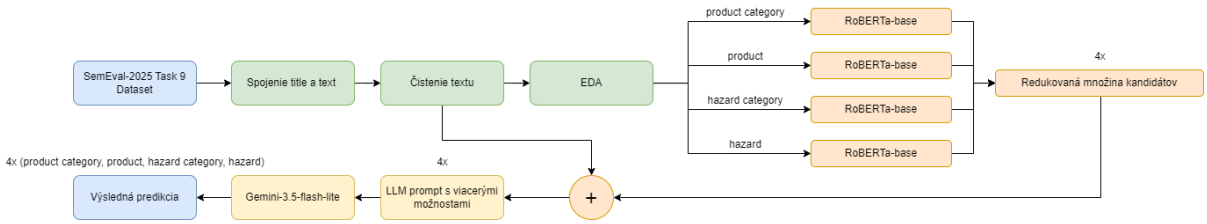
Proces hodnotenia je vykonávaný samostatne pre ST1 a ST2. V ST1 sú použité kategórie hazardu a produktu, zatiaľ čo v ST2 sú použité konkrétne hazardy a produkty.

3.1 Metodológia

Hlavným cieľom baseline riešenia bude vytvorenie reprodukovateľného riešenia, ktoré bude zahŕňať prvky spomenutých systémov a zároveň zostane výpočtovo nenáročné, aby ho bolo možné v druhej časti tohto projektu ďalej rozšíriť. Výsledné skóre tohto riešenia bude následne porovnané so ostatnými referenčnými riešeniami a taktiež systémami, ktoré tvoria oficiálny rebríček, aby bolo možné určiť, na ktorom mieste by sa v jednotlivých podúlohách umiestnilo.

Pre naše baseline riešenie bude použitý oficiálny dataset zverejnený na platforme Zenodo [7], pričom budú použité aj oficiálne rozdelenia na trénovaciu, validačnú a testovaciu množinu poskytnuté organizátormi súťaže. Veľkosti týchto podmnožín sú:

- Trénovacia množina – 5 082 (∼76,5 %)



Obr. 6: Pipeline navrhnutého baseline riešenia.

- Validačná množina – 565 (∼8,5 %)
- Testovacia množina – 997 (∼15,0 %)

4 Návrh a implementácia baseline riešenia

V tejto kapitole bude podrobne opísaný proces návrhu a implementácie baseline riešenia. Podkapitola o návrhu poskytne všeobecný prehľad architektúry systému a vysvetlí, prečo boli zvolené jednotlivé časti, zatiaľ čo podkapitola o implementácii konkrétne opíše každý proces, ktorý je súčasťou pipeline.

4.1 Návrh baseline riešenia

Na objasnenie úvah, ktoré viedli k návrhu systému, slúži nasledujúci zoznam, ktorý všeobecne opisuje trendy nájdené v preskúmaných systémoch, pričom každý bod sa vyskytuje aspoň v dvoch riešeniach.

- Spojenie vstupných atribútov do jedného textu + čistenie textu (SRCB, Anastasia, PATeam)
- Využitie augmentácie dát (všetky preskúmané riešenia)
- Využitie LLM na augmentáciu dát (SRCB, MyMy, PATeam)
- Využitie architektúry BERT aspoň na čiastočnú klasifikáciu (SRCB, Anastasia, MyMy)
- Využitie doladených LLM na klasifikáciu (SRCB, MyMy, PATeam)
- Ensemble stratégie (všetky skúmané riešenia)

S ohľadom na tieto trendy sa náš tím rozhodol, že baseline riešenie bude v podstate zjednodušenou verziou riešenia SRCB s tromi kľúčovými zmenami:

1. Augmentácia dát bude vykonaná pomocou metódy EDA [12], nie pomocou LLM. Hoci tím zvažoval využitie LLM na tento účel, nakoniec bolo rozhodnuté, že by to bolo pre baseline riešenie príliš pokročilé z dôvodu zložitosti, časovej náročnosti a s tým spojených nákladov na takéto využitie LLM.
2. Pri trénovaní modelu BERT bude použitá stratová funkcia focal loss [9], konkrétne jej binárna varianta (z dôvodu použitia prístupu one-vs-all). Ide o myšlienku prevzatú z riešenia Anastasia, ktorého autori tvrdia, že táto funkcia môže pomôcť pri nevyvážených datasetoch. Keďže EDA vo všeobecnosti vytvára menej rozmanité vzorky ako generovanie pomocou LLM, väčšia časť zodpovednosti za riešenie nevyváženosti tried pripadá na stratovú funkciu, a preto by sa focal loss mohla ukázať ako výhodná.
3. LLM použitý na finálnu predikciu nebude doladený ani nebude využívať modul label attention z riešenia SRCB. Namiesto toho mu bude jednoducho poskytnutý prompt s výberom z viacerých možností, ktorý obsahuje zúženú množinu označení z modelu BERT.

Hoci toto riešenie v skutočnosti využíva iba tri zo šiestich spomenutých trendov, bolo rozhodnuté, že bude vhodným a výpočtovo nenáročným začiatočným bodom, ktorý by mohol byť potenciálne jednoducho rozšírený o ďalšie zo spomenutých trendov. Pre prehľad navrhutej pipeline viď obrázok 6.

4.2 Implementácia baseline riešenia

Táto podkapitola opisuje jednotlivé kroky pipeline baseline riešenia v poradí, v akom sú vykonávané: príprava dát, augmentácia dát, výber kandidátov a výsledná predikcia pomocou LLM.

4.2.1 Príprava dát

Z trénovacej množiny sú najprv odstránené vzorky, ktoré nie sú v anglickom jazyku, čím vznikne 5 082 trénovacích vzoriek zodpovedajúcich oficiálnemu rozdeleniu dát. Atribúty *title* a *text* každej vzorky sú následne spojené do jedného textu, pričom zvyšné atribúty (*year*, *month*, *day* a *country*) nie sú použité. Podľa vzoru riešenia SRCB sú texty vyčistené normalizáciou bielych znakov a zalomení riadkov, odstránením duplicitných úsekov a prevodom na malé písmená. Každé zo štyroch cieľových označení (kategória hazardu a kategória produktu pre ST1, konkrétny hazard a konkrétny produkt pre ST2) je považované za samostatný klasifikačný problém.

4.2.2 Augmentácia dát

Na riešenie nevyváženosti tried je trénovacia množina augmentovaná pomocou metódy EDA [12], a to až po rozdelení dát, aby sa žiadne syntetické vzorky nedostali do validačnej ani testovacej množiny. Vytvorený je jeden augmentovaný dataset zdieľaný všetkými štyrmi klasifikátormi, pričom každá augmentovaná vzorka si zachováva všetky štyri označenia pôvodnej vzorky. Augmentácia je riadená označením konkrétneho produktu, ktoré obsahuje najviac málo zastúpených tried: každá trieda s menej ako 10 vzorkami je doplnená na tento počet EDA variantmi jej existujúcich vzoriek, čím sa nepriamo zvyšuje aj zastúpenie zvyšných označení.

Každý variant vzniká aplikovaním jednej zo štyroch operácií EDA (nahradenie synonymom, náhodné vloženie, náhodná zámena, náhodné vymazanie), ktoré sa medzi variantmi striedajú, pričom je upravených približne 10 % slov textu ($\alpha = 0{,}1$). Synonymá sú čerpané z najčastejšieho významu slova v databáze WordNet a zámeny prebiehajú iba v rámci jednej vety. Slová označení hazardu a produktu danej vzorky (vrátane ich tvarov) sú chránené pred úpravou a nadpis zostáva nezmenený, takže EDA je aplikovaná iba na *text*. Pri náhodnom seede 42 bolo pridaných 6 903 syntetických vzoriek, čím sa veľkosť trénovacej množiny zvýšila z 5 082 na 11 985.

4.2.3 Modul výberu kandidátov

Modul výberu kandidátov zužuje množinu možných označení pred finálnou predikciou pomocou LLM. Model RoBERTa-base je doladený samostatne pre každý zo štyroch klasifikačných problémov. Podľa vzoru riešenia SRCB je použitý prístup one-vs-all, implementovaný ako multi-label klasifikačná hlava s jedným sigmoidovým výstupom pre každé označenie z trénovacej množiny.

Modely sú trénované pomocou binárnej varianty focal loss [9] s parametrami $\gamma = 2$ a $\alpha = 0{,}25$ a optimalizátora AdamW s rýchlosťou učenia (learning rate) 10^{-5} pre enkodér a 10^{-4} pre klasifikačnú hlavu, batch size 16 a maximálnou dĺžkou vstupu 512 tokenov. Trénovanie trvá najviac 10 epoch s predčasným zastavením, ak sa makro-F1 skóre na validačnej množine nezlepší počas 2 epoch.

Ako kandidáti sú vybrané všetky označenia s pravdepodobnosťou vyššou ako 0,5; ak túto hranicu žiadne neprekročí, je vybraných 5 najpravdepodobnejších označení, pričom počet kandidátov je obmedzený na 15. Recall kandidátov, t. j. podiel vzoriek, ktorých správne označenie sa nachádza medzi kandidátmi, dosiahol na validačnej množine hodnotu 0,8973 pre hazard a 0,6372 pre produkt, pri priemernej dĺžke zoznamu 1,42, resp. 2,65 kandidátov. Pre ST1 boli modelu LLM predložené všetky kategórie.

4.2.4 Predikcia pomocou LLM

Finálna predikcia je vykonaná modelom Gemini 3.5 Flash-Lite bez doladenia. Pre každú vzorku a klasifikačný problém je zostavený prompt s výberom z viacerých možností, ktorý obsahuje krátky opis úlohy, vyčistený nadpis a text vzorky (skrátený na najviac 600 slov) a kandidátske označenia zoradené podľa pravdepodobnosti vo forme číslovaného zoznamu, spolu s inštrukciou odpovedať práve jedným z nich. Ak je k dispozícii iba jeden kandidát, LLM nie je volané a tento kandidát je priamo použitý ako predikcia. Formát promptu je zobrazený na obrázku 7.

Teplota je nastavená na 0 a úroveň uvažovania (*thinking level*) na *minimal*. Odpovede LLM sú priradené k množine označení: pri presnej zhode (po normalizácii a odstránení čísla poradia) je použité zodpovedajúce označenie, inak je pomocou miery podobnosti reťazcov Ratcliff/Obershelp (funkcia `get_close_matches` z knižnice `difflib`,

```python
def build_prompt(task, title, text, options):
    numbered = "\n".join(f"{i}. {o}" for i, o in enumerate(options, 1))
    return (
        "You are classifying food recall reports.\n\n"
        f"Title: {title}\n"
        f"Text: {cap_words(text)}\n\n"
        f"{TASK_QUESTION[task]}\n"
        f"{numbered}\n\n"
        "Answer with exactly one label from the list, copied exactly, and nothing else."
    )
```

Obr. 7: Kód použitý na generáciu promptu pre LLM použitý na určenie výsledného predikovaného označenia.

prah 0,8) vybrané najpodobnejšie označenie. Ak nie je nájdené dostatočne podobné označenie, je použitý kandidát s najvyššou pravdepodobnosťou z modulu výberu kandidátov.

5 Výsledky baseline riešenia

Naše riešenie dosiahlo v prípade používania len top-1 od BERT modelu ST1 skóre 0.7348, čím sa by umiestnilo na 19. mieste, a v ST2 skóre 0.4680, čím sa by umiestnilo na 9.(!) mieste. V prípade používania BERT spolu s LLM naše riešenie dosiahlo nižšie skóre pre ST1 – 0.6238 čím sa by umiestnilo až na 23. mieste ale na kontrast sa skóre pre ST2 zvýšilo na 0.4958, čím by sa umiestnilo na dokonca až 4.(!!) mieste.

Tento baseline a spojené súbory sú verejne dostupné na našom githube [13].

6 Použitie agentov a LLM mimo riešenia

Počas vývoja tohto projektu bol použitý LLM, konkrétne Claude Opus 5.5, na:

- Generácia kódu, debugging, testovanie (z dôvodu interakcie viacerých pokročilých technológií sme úvážili použitie LLM pre tieto účely ako vhodné)
- Kritiku textu (napr. „Here is my section on MyMy, what do you think? Is there anything that should be added?“)
- Objasnenie pojmov (napr. „Was the pipeline for both subtasks the same?“, „How is the sample and relevant documents combined into a prompt, are they just attached or are they somehow embedded together?“)
- Extrakciu obrázkov z dokumentov (napr. „Can you extract the LLM prediction module image from page 999 for me?“)
- Preklad textu

Literatúra

[1] Yuming Zhang, Hongyu Li, Yongwei Zhang, Shanshan Jiang, and Bin Dong. SRCB at SemEval-2025 task 9: LLM finetuning approach based on external attention mechanism in the food hazard detection. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 996–1003, Vienna, Austria, July 2025. Association for Computational Linguistics.

[2] Tung Thanh Le, Tri Minh Ngo, and Trung Hieu Dang. Anastasia at SemEval-2025 task 9: Subtask 1, ensemble learning with data augmentation and focal loss for food risk classification. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 141–147, Vienna, Austria, July 2025. Association for Computational Linguistics.

[3] Ben Phan and Jung-Hsien Chiang. MyMy at SemEval-2025 task 9: A robust knowledge-augmented data approach for reliable food hazard detection. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 812–822, Vienna, Austria, July 2025. Association for Computational Linguistics.

[4] Xue Wan, Fengping Su, Ling Sun, Yuyang Lin, and Pengfei Chen. PATeam at SemEval-2025 task 9: LLM-augmented fusion for AI-driven food safety hazard detection. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 1912–1918, Vienna, Austria, July 2025. Association for Computational Linguistics.

[5] Korbinian Randl, John Pavlopoulos, Aron Henriksson, Tony Lindgren, and Juli Bakagianni. SemEval-2025 task 9: The food hazard detection challenge. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2523–2534, Vienna, Austria, July 2025. Association for Computational Linguistics.

[6] Korbinian Randl, John Pavlopoulos, Aron Henriksson, and Tony Lindgren. CICLe: Conformal in-context learning for largescale multi-class food risk classification. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar, editors, *Findings of the Association for Computational Linguistics: ACL 2024*, pages 7695–7715, Bangkok, Thailand, August 2024. Association for Computational Linguistics.

[7] Korbinian Randl, John Pavlopoulos, Tony Lindgren, Aron Henriksson, and Giannis Stoitsis. Food recall incidents, March 2025.

[8] Sakshi Pant, Er Narinder Yadav, Monnie Sharma, Yash Bedi, Anshuman Raturi, et al. Web scraping using beautiful soup. In *2024 international conference on knowledge engineering and communication systems (ICKECS)*, volume 1, pages 1–6. IEEE, 2024.

[9] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, pages 2980–2988, 2017.

[10] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.

[11] Leo Breiman. Bagging predictors. *Machine learning*, 24(2):123–140, 1996.

[12] Jason Wei and Kai Zou. Eda: Easy data augmentation techniques for boosting performance on text classification tasks. In *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*, pages 6382–6388, 2019.

[13] Ján Schmiedbauer, Patrik Sedlák, and Anastasiia Kolisnyk. nlp-semeval-2025-task-9. `https://github.com/PinkFloppa/nlp-semeval-2025-task-9`, 2026. GitHub repository, accessed 2026-10-26.